



INSTITUTO POLITÉCNICO NACIONAL
ESCUELA SUPERIOR DE CÓMPUTO
TEORÍA DE LA COMPUTACIÓN
ING. EN SISTEMAS COMPUTACIONALES

Práctica 7: Analizador de Texto (segunda parte)

Integrantes:

Espinoza León Jaqueline Viridiana

García Zacarías Angel Emmanuel

Hurtado Morales Emiliano

Profesora: Luz María Sánchez García

Fecha de entrega: 10/06/22

Ciclo Escolar: 2022 - 1

Índice

Planteamiento del problema	2
Actividades	2
Pruebas	4
1.- Programación de detección de cadenas.	4
2.- Lectura de archivo fuente	5
3.- Salida en pantalla de los resultados	6
Anexos	7

1. Planteamiento del problema

Se diseñó un programa en lenguaje C, capaz de leer un archivo y detectar cadenas.

Después de eso, indica la frecuencia con la que se repite cada uno y mostrará el porcentaje que ocupa en el archivo.

2. Actividades

1. Se programó en ANSI C, el número de veces que aparece una cadena y el porcentaje en el que el carácter ocupa en el texto.
2. El programa es capaz de leer un archivo fuente, además de detectar cadenas, y mostrar su frecuencia y su porcentaje.
3. Mostramos los resultados obtenidos.

```
asm se repite una vez, es un 0.0433 %
auto se repite una vez, es un 0.0578 %
bool se repite una vez, es un 0.0578 %
catch se repite una vez, es un 0.0722 %
compl se repite una vez, es un 0.0722 %
continue se repite una vez, es un 0.1156 %
do se repite 7 veces, es un 0.2023 %
else se repite 5 veces, es un 0.2890 %
export se repite una vez, es un 0.0867 %
float se repite 13 veces, es un 0.9392 %
goto se repite una vez, es un 0.0578 %
int se repite 17 veces, es un 0.7369 %
namespace se repite una vez, es un 0.1300 %
or_eq se repite una vez, es un 0.0722 %
public se repite una vez, es un 0.0867 %
return se repite 4 veces, es un 0.3468 %
sizeof se repite 4 veces, es un 0.3468 %
struct se repite 11 veces, es un 0.9536 %
this se repite una vez, es un 0.0578 %
try se repite una vez, es un 0.0433 %
typename se repite una vez, es un 0.1156 %
not_eq se repite una vez, es un 0.0867 %
using se repite una vez, es un 0.0722 %
volatile se repite una vez, es un 0.1156 %
and se repite una vez, es un 0.0433 %
bitand se repite una vez, es un 0.0867 %
break se repite una vez, es un 0.0722 %
char se repite 28 veces, es un 1.6183 %
const se repite una vez, es un 0.0722 %
default se repite una vez, es un 0.1011 %
double se repite una vez, es un 0.0867 %
enum se repite una vez, es un 0.0578 %
extern se repite una vez, es un 0.0867 %
for se repite 3 veces, es un 0.1300 %
if se repite 9 veces, es un 0.2601 %
long se repite una vez, es un 0.0578 %
new se repite una vez, es un 0.0433 %
operator se repite una vez, es un 0.1156 %
private se repite una vez, es un 0.1011 %
register se repite una vez, es un 0.1156 %
short se repite una vez, es un 0.0722 %
static se repite una vez, es un 0.0867 %
```

```
switch se repite una vez, es un 0.0867 %
throw se repite una vez, es un 0.0722 %
typedef se repite una vez, es un 0.1011 %
union se repite una vez, es un 0.0722 %
virtual se repite una vez, es un 0.1011 %
wchar_t se repite una vez, es un 0.1011 %
xor se repite una vez, es un 0.0433 %
and_eq se repite una vez, es un 0.0867 %
bitor se repite una vez, es un 0.0722 %
case se repite una vez, es un 0.0578 %
class se repite una vez, es un 0.0722 %
```

```
const_cast se repite una vez, es un 0.1445 %
delete se repite una vez, es un 0.0867 %
dynamic_cast se repite una vez, es un 0.1734 %
explicit se repite una vez, es un 0.1156 %
false se repite una vez, es un 0.0722 %
friend se repite una vez, es un 0.0867 %
inline se repite una vez, es un 0.0867 %
mutable se repite una vez, es un 0.1011 %
not se repite una vez, es un 0.0433 %
or se repite 10 veces, es un 0.2890 %
protected se repite una vez, es un 0.1300 %
reinterpret_cast se repite una vez, es un 0.2312 %
signed se repite una vez, es un 0.0867 %
static_cast se repite una vez, es un 0.1589 %
template se repite una vez, es un 0.1156 %
true se repite una vez, es un 0.0578 %
typeid se repite una vez, es un 0.0867 %
unsigned se repite una vez, es un 0.1156 %
void se repite 5 veces, es un 0.2890 %
xor_eq se repite una vez, es un 0.0867 %
while se repite 3 veces, es un 0.2167 %
```

Hay 74 cadenas.

4. Finalmente responda a las siguientes preguntas

a) ¿Es fácil o difícil trabajar con cadenas ?¿Por qué?

Es complejo trabajar con cadenas, porque implica una concatenación de caracteres que puede llegar a ser difícil de manejar. Esto implica que se empleen apuntadores y estructuras de datos como colas, listas, entre otros. Es por ello que es muy distinto trabajar con caracteres solitarios que con un conjunto ordenado de ellos.

b) ¿Qué errores se presentaron al realizar la práctica?¿Se pudieron resolver?

El programa dejaba de funcionar al tener que realizar una gran cantidad de ciclos, la manera de solucionar esto fue dejar de lado los arreglos para reemplazarlos por *queues*, ya que estas no nos generaban estos inconvenientes.

c) ¿En qué aplicaciones ha visto se ocupa la detección de cadenas con su porcentaje de ocurrencia?

Lo más cercano a eso sería la herramienta de búsqueda de algunos IDE, Editores de Código, Procesadores de Texto, etc.

d) ¿En qué otros lenguajes se pueden manejar las cadenas con facilidad?

C++ y Python plantean muchas facilidades para el manejo de cadenas, puesto que ya tiene varias funciones o métodos predefinidos que sólo se requiere ingresar un argumento para que de todo lo demás se encargue la máquina.

e) ¿Qué recomendaciones daría a nuevos equipos para realizar la práctica?

Empezar a aprender nuevos lenguajes de programación de alto nivel, de forma que puedan hacer uso de ellos en estas prácticas y logren facilitar el desarrollo de la misma. Asimismo, si van a hacer uso de lenguajes de bajo nivel, tratar de hacer su programa lo más elemental posible y comprobar cada parte del código, de modo que entiendan plenamente el funcionamiento de su programa.

3. Pruebas

1.- Programación de detección de cadenas.

a) Detección de cadenas.

```
////////////////////////////////////  
/*Descripción de función:  
Funcion contarRes, Cuenta las palabras reservadas.  
Input: un arreglo del texto, la palabra reservada, struct de tipo stat, la posición y la suma total  
Output: void.  
*/  
  
void contarRes(char *arreglo, char *res, struct stat sb, int pos){  
    // variables  
    int i;  
    int cont;  
    int lon;  
  
    lon = 0;  
    cont = 1;  
    // recorrido  
    for(i = pos; i<sb.st_size;i++){  
        //recorremos  
        if(lon == strlen(res)){ // Son iguales por su longitud  
  
            if(arreglo[i] == ' ' || arreglo[i] == '\n' || arreglo[i] == '<' ||  
|| arreglo[i] == '*' || arreglo[i] == '+' || arreglo[i] == '-' || arreglo[i] == '[' || arreglo[i] ==  
'{' || arreglo[i] == '(' || arreglo[i] == ')' || arreglo[i] == ';' || arreglo[i] == ',' || arreglo[i]  
== '') // revisamos el siguiente valor  
                cont++;  
            else lon = 0; //reseteamos la longitud de la palabra  
        } else{  
            if(res[lon] == arreglo[i]){ // Si son iguales, su tamaño coincide  
                lon++;  
            } else lon = 0;  
        }  
    }  
}
```

b) Mostrar frecuencia y porcentaje

```
if(cont > 1)  
    printf("%s se repite %d veces, es un %.4f %% \n", res ,cont, obtenerPorcentaje((float)  
(strlen(res) * cont),sb));  
else  
    printf("%s se repite una vez, es un %.4f %% \n", res , obtenerPorcentaje((float)  
(strlen(res)),sb));  
}
```

```

////////////////////////////////////
/*Descripción de función:
Funcion obtenerPorcentaje, se obtiene el porcentaje.
Input: un float que representa la frecuencia con la que se repite, struct de tipo stat,
Output: retorna un porcentaje.
*/

float obtenerPorcentaje(float num, struct stat sb){
    return (num * 100 /sb.st_size);
}

```

2.- Lectura de archivo fuente

```

void entradaDatos(char *nombreArchivo, char *arreglo, struct stat sb){
    char bufer[1];
    FILE *archivo;
    size_t bytesLeidos;
    int i;

    i = 0;

    archivo = fopen(nombreArchivo, "rb"); // Abrir en modo read binario
    // Si es NULL, entonces no existe, o no se pudo abrir
    if (!archivo) {
        printf("¡No se pudo abrir el archivo %s!", nombreArchivo);
    }

    // Mientras no alcancemos el EndOfLine del archivo...
    while (i<sb.st_size) {
        // Leer dentro del búfer; fread regresa el número de bytes leídos
        bytesLeidos = fread(bufer, sizeof(char), sizeof(bufer), archivo);
        arreglo[i] = bufer[0];
        i++;
    }
    // Al final, se cierra el archivo
    fclose(archivo);
}

```

Para ejecutar el programa, se debe escribir el nombre del archivo a leer al lado del .exe y este debe estar en el mismo directorio.

3.- Salida en pantalla de los resultados

```
asm se repite una vez, es un 0.0433 %
auto se repite una vez, es un 0.0578 %
bool se repite una vez, es un 0.0578 %
catch se repite una vez, es un 0.0722 %
compl se repite una vez, es un 0.0722 %
continue se repite una vez, es un 0.1156 %
do se repite 7 veces, es un 0.2023 %
else se repite 5 veces, es un 0.2890 %
export se repite una vez, es un 0.0867 %
float se repite 13 veces, es un 0.9392 %
goto se repite una vez, es un 0.0578 %
int se repite 17 veces, es un 0.7369 %
namespace se repite una vez, es un 0.1300 %
or_eq se repite una vez, es un 0.0722 %
public se repite una vez, es un 0.0867 %
return se repite 4 veces, es un 0.3468 %
sizeof se repite 4 veces, es un 0.3468 %
struct se repite 11 veces, es un 0.9536 %
this se repite una vez, es un 0.0578 %
try se repite una vez, es un 0.0433 %
typename se repite una vez, es un 0.1156 %
not_eq se repite una vez, es un 0.0867 %
using se repite una vez, es un 0.0722 %
volatile se repite una vez, es un 0.1156 %
and se repite una vez, es un 0.0433 %
bitand se repite una vez, es un 0.0867 %
break se repite una vez, es un 0.0722 %
char se repite 28 veces, es un 1.6183 %
const se repite una vez, es un 0.0722 %
default se repite una vez, es un 0.1011 %
double se repite una vez, es un 0.0867 %
enum se repite una vez, es un 0.0578 %
extern se repite una vez, es un 0.0867 %
for se repite 3 veces, es un 0.1300 %
if se repite 9 veces, es un 0.2601 %
long se repite una vez, es un 0.0578 %
new se repite una vez, es un 0.0433 %
operator se repite una vez, es un 0.1156 %
private se repite una vez, es un 0.1011 %
register se repite una vez, es un 0.1156 %
short se repite una vez, es un 0.0722 %
static se repite una vez, es un 0.0867 %
switch se repite una vez, es un 0.0867 %
throw se repite una vez, es un 0.0722 %
typedef se repite una vez, es un 0.1011 %
union se repite una vez, es un 0.0722 %
virtual se repite una vez, es un 0.1011 %
wchar_t se repite una vez, es un 0.1011 %
xor se repite una vez, es un 0.0433 %
and_eq se repite una vez, es un 0.0867 %
bitor se repite una vez, es un 0.0722 %
case se repite una vez, es un 0.0578 %
class se repite una vez, es un 0.0722 %
const_cast se repite una vez, es un 0.1445 %
delete se repite una vez, es un 0.0867 %
dynamic_cast se repite una vez, es un 0.1734 %
explicit se repite una vez, es un 0.1156 %
false se repite una vez, es un 0.0722 %
friend se repite una vez, es un 0.0867 %
inline se repite una vez, es un 0.0867 %
mutable se repite una vez, es un 0.1011 %
not se repite una vez, es un 0.0433 %
or se repite 10 veces, es un 0.2890 %
protected se repite una vez, es un 0.1300 %
reinterpret_cast se repite una vez, es un 0.2312 %
signed se repite una vez, es un 0.0867 %
static_cast se repite una vez, es un 0.1589 %
template se repite una vez, es un 0.1156 %
true se repite una vez, es un 0.0578 %
typeid se repite una vez, es un 0.0867 %
unsigned se repite una vez, es un 0.1156 %
void se repite 5 veces, es un 0.2890 %
xor_eq se repite una vez, es un 0.0867 %
while se repite 3 veces, es un 0.2167 %
```

Hay 74 cadenas.

4. Anexos

Instrucciones de compilación.

Estando en el símbolo de sistema para desarrolladores (Windows) o en la terminal (Linux), se escribe en la línea de comando lo siguiente:

- Windows
 - Compilación: cl Practica7.c
 - Ejecución: Practica7.c codigoFuente.c
- Linux
 - Compilación: gcc Practica7.c
 - Ejecución: ./Practica7.c codigoFuente.c

Código fuente

- cola.h

```
#ifndef cola_h
#define cola_h

typedef struct NodoC{
    char dato;
    struct NodoC *sig;
}*ApNodo;

typedef struct Cnodo{
    ApNodo prim;
    ApNodo ulti;
}*Cola;

Cola nueva(){
    Cola t = (Cola)malloc(sizeof(struct Cnodo));
    t->prim=t->ulti=NULL;
    return t;
}

int esnueva(Cola q){return ((q->prim==NULL)&&(q->ulti==NULL));}

char primero(Cola q){return q->prim->dato;}

Cola formar(Cola q, char e){
    ApNodo t = (ApNodo)malloc(sizeof(struct NodoC));
    t->dato=e;
    t->sig=NULL;
    if(esnueva(q)){
        q->prim=q->ulti=t;
    } else{
        q->ulti->sig=t;
        q->ulti=t;
    }
    return q;
}
```



```

Cola desformar(Cola q){
    ApNodo t;
    if(q->prim==q->ulti){
        free(q->prim);
        free(q);
        return nueva();
    } else{
        t = q->prim;
        q->prim=q->prim->sig;
        free(t);
        return q;
    }
}

int comparar(Cola q, char *cadena, int size, int pos){
    if(esnueva(q) && cadena[pos] == '\\0'){
        return 1;
    } else if(esnueva(q) && cadena[pos] != '\\0'){
        return 0;
    } else if(!esnueva(q) && cadena[pos] == '\\0'){
        return 0;
    } else if(primero(q) != cadena[pos]){
        return 0;
    } else if(primero(q) == cadena[pos]){
        return comparar(desformar(q),cadena,size,pos + 1);
    }
}
#endif

```

- Practica7.c

```

/*
NOMBRE DE PROGRAMA: Analizador de texto (segunda parte)
DESCRIPCIÓN: Partiendo de cualquier tipo de archivo, se lee de forma binaria y se guarda cada byte
en un arreglo del tamaño del archivo. Posteriormente, se hace un análisis del arreglo, para obtener
la información necesaria
FECHA: junio 2022
VERSIÓN: 2.0
AUTOR(ES):
    Espinoza León Jaqueline Viridiana
    García Zacarías Angel Emmanuel
    Hurtado Morales Emiliano
*/

//*****
//LIBRERIAS INCLUIDAS
//*****

#include <stdio.h> // Todas las funciones como fread, fwrite, fopen, fclose y printf
#include <stdlib.h> // EXIT_FAILURE y EXIT_SUCCESS
#include <inttypes.h>
#include <unistd.h>
#include <sys/stat.h>
#include <fcntl.h>
#include <string.h>
#include "cola.h"

#define TAM 100

//*****
//DECLARACION DE ESTRUCTURAS
//*****

//*****
//DECLARACIÓN DE FUNCIONES
//*****

void entradaDatos(char*, char*, struct stat);
float obtenerPorcentaje(float, struct stat);
void contarRes(char*, char*, struct stat, int);

//*****
//PROGRAMA PRINCIPAL
//*****

/*Descripción de la función:
Funcion main, se ingresa el archivo a analizar y realiza todas las llamadas a funciones que
permiten
su análisis léxico.
Input: Archivo de entrada.
Output: Ninguno.
*/

```

```

int main(int argc, char *argv[]) {

    FILE *archivo;
    char *nombreArchivo;
    char *arreglo;
    int *numC;
    int alt;
    int i;
    int k;
    float tamor;
    float tamcom;
    char reser[74][17] = {"asm\0"}, {"auto\0"}, {"bool\0"}, {"catch\0"},
{"compl\0"}, {"continue\0"}, {"do\0"}, {"else\0"}, {"export\0"}, {"float\0"},
{"goto\0"}, {"int\0"}, {"namespace\0"}, {"or_eq\0"}, {"public\0"}, {"return\0"},
{"sizeof\0"}, {"struct\0"}, {"this\0"}, {"try\0"}, {"typename\0"}, {"not_eq\0"},
{"using\0"}, {"volatile\0"}, {"and\0"}, {"bitand\0"}, {"break\0"}, {"char\0"},
{"const\0"}, {"default\0"}, {"double\0"}, {"enum\0"}, {"extern\0"}, {"for\0"},
{"if\0"}, {"long\0"}, {"new\0"}, {"operator\0"}, {"private\0"}, {"register\0"},
{"short\0"}, {"static\0"}, {"switch\0"}, {"throw\0"}, {"typedef\0"}, {"union\0"},
{"virtual\0"}, {"wchar_t\0"}, {"xor\0"}, {"and_eq\0"}, {"bitor\0"}, {"case\0"},
{"class\0"}, {"const_cast\0"}, {"delete\0"}, {"dynamic_cast\0"}, {"explicit\0"},
{"false\0"}, {"friend\0"}, {"inline\0"}, {"mutable\0"}, {"not\0"}, {"or\0"},
{"protected\0"}, {"reinterpret_cast\0"}, {"signed\0"}, {"static_cast\0"},
{"template\0"}, {"true\0"}, {"typeid\0"}, {"unsigned\0"}, {"void\0"},
{"xor_eq\0"}, {"while\0"};

    nombreArchivo = argv[1];

    // Checa el tamaño del archivo y manda un error si no logra realizarlo
    struct stat sb;
    if (stat(nombreArchivo, &sb) == -1){
        perror("stat");
        exit(EXIT_FAILURE);
    }
    tamor = sb.st_size;

    // Se crea el arreglo dinámico
    arreglo = malloc(sizeof(char)*sb.st_size);

    entradaDatos(nombreArchivo, arreglo, sb);

    for(i = 0; i<74; i++){
        contarRes(arreglo, reser[i], sb, 0);
    }

    printf("\nHay %d cadenas.", i);

    return EXIT_SUCCESS;
}

```

```

//*****
//DEFINICIÓN DE FUNCIONES
//*****

// //////////////////////////////////////

/*Descripción de función:
Funcion entradaDatos, permite la inserción de cada byte del archivo en el arreglo previamente
creado.
Input: Puntero al archivo, puntero al arreglo y struct stat sb, que habilita saber de que tamaño es
el archivo.
Output: Arreglo llenado completamente.
Observaciones: La inserción es muy rápida y no conlleva
mucho tiempo de procesamiento.
*/

void entradaDatos(char *nombreArchivo, char *arreglo, struct stat sb){
    char bufer[1];
    FILE *archivo;
    size_t bytesLeidos;
    int i;

    i = 0;

    archivo = fopen(nombreArchivo, "rb"); // Abrir en modo read binario
    // Si es NULL, entonces no existe, o no se pudo abrir
    if (!archivo) {
        printf("¡No se pudo abrir el archivo %s!", nombreArchivo);
    }

    // Mientras no alcancemos el EndOfLine del archivo...
    while (i<sb.st_size) {
        // Leer dentro del búfer; fread regresa el número de bytes leídos
        bytesLeidos = fread(bufer, sizeof(char), sizeof(bufer), archivo);
        arreglo[i] = bufer[0];
        i++;
    }
    // Al final, se cierra el archivo
    fclose(archivo);
}

// //////////////////////////////////////

/*Descripción de función:
Funcion obtenerPorcentaje, se obtiene el porcentaje.
Input: un float que representa la frecuencia con la que se repite, struct de tipo stat,
Output: retorna un porcentaje.
*/

float obtenerPorcentaje(float num, struct stat sb){
    return (num * 100 /sb.st_size);
}

```

```

////////////////////////////////////
/*Descripción de función:
Funcion contarRes, Cuenta las palabras reservadas.
Input: un arreglo del texto, la palabra reservada, struct de tipo stat, la posición y la suma total
Output: void.
*/

void contarRes(char *arreglo, char *res, struct stat sb, int pos){
    // variables
    int i;
    int cont;
    int lon;

    lon = 0;
    cont = 1;
    // recorrido
    for(i = pos; i<sb.st_size;i++){
        //recorremos
        if(lon == strlen(res)){ // Son iguales por su longitud

            if(arreglo[i] == ' ' || arreglo[i] == '\n' || arreglo[i] == '<'
|| arreglo[i] == '*' || arreglo[i] == '+' || arreglo[i] == '-'|| arreglo[i] == '['|| arreglo[i] ==
'{'|| arreglo[i] == '('|| arreglo[i] == ')'|| arreglo[i] == ';'|| arreglo[i] == ',' || arreglo[i]
== '"') // revisamos el siguiente valor
                cont++;
            else lon = 0; //reseteamos la longitud de la palabra
        } else{
            if(res[lon] == arreglo[i]){ // Si son iguales, su tamaño coincide
                lon++;
            } else lon = 0;
        }
    }
    if(cont > 1)
        printf("%s se repite %d veces, es un %.4f %% \n", res ,cont, obtenerPorcentaje((float)
(strlen(res) * cont),sb));
    else
        printf("%s se repite una vez, es un %.4f %% \n", res , obtenerPorcentaje((float)
(strlen(res)),sb));
}

```